

## Tema 7: Redes Bayesianas

- Repaso de probabilidad
  - ❖ Distribuciones de probabilidad conjunta
  - ❖ Teorema de Bayes y regla de la cadena
- Redes Bayesianas
  - ❖ Definición
  - ❖ Inferencia
    - Exacta
    - Aproximada

## Breve introducción a la probabilidad

### Introducción (I)

- Teoría de la probabilidad
  - Dos aproximaciones, frecuencial y bayesiana
- Aproximación frecuencial
  - La probabilidad  $P$  de un evento  $a$   
 $P(a)$  se define por la frecuencia de  $a$  basada en las observaciones pasadas
  - 60% de los nacimientos en España son niñas
    - $a$  = 'Elegir al azar a un bebe y que sea niña'
    - $P(a) = 0.6$
  - Utilizamos el pasado para predecir el presente

## Breve introducción a la probabilidad

### Introducción (II)

- Aproximación Bayesiana
  - Razonar sobre creencias en condiciones de incertidumbre
  - Deseamos conocer la probabilidad de que una nueva arquitectura de ordenador funcione correctamente
    - No hay instancias previas
  - $a$  = 'gana el CD Guadalajara la liga del 2022'
    - ¿ $P(a)$ ?
    - $P(a|Diego) = 0,7$
    - $P(a|Conocimiento\ previo)$  : Medida de conocimiento, si este conocimiento previo permanece constante podemos escribir  $P(a)$
    - ¿Consistencia interna?

## Breve introducción a la probabilidad

### Axiomas de probabilidad

#### Axiomas de la probabilidad

- I.  $P(a)$  debe ser un  $n^\circ$  entre  $[0,1]$
- II. Si  $a$  es un evento cierto, entonces  $P(a)=1$
- III. Si  $a$  y  $b$  son mutuamente exclusivos entonces  
 $P(a \vee b) = P(a) + P(b)$

#### De esta manera...

- $P(a + \neg a) = 1$  (por el 2º axioma)

## Breve introducción a la probabilidad

### Variables y distribuciones de probabilidad

A = 'Ganador de la liga en el 2022'

$A = \{a_1, a_2, a_3, \dots\}$

- ¿ $P(a_1 + a_2) = 1$ ?
  - No es exhaustivo
- $P(a_1 + a_2 + a_3 + \dots) = 1$
- Probabilidad total

$$\sum_{i=1}^n P(a_i) = 1$$

## Breve introducción a la probabilidad

### Distribuciones conjuntas y marginalización

- A: 'funciona el monitor' =  $\{m_1, m_2, m_3\}$   
B: 'funciona la tarjeta de video' =  $\{v_1, v_2\}$   
¿ $P(A, B)$ ?
- Distribución conjunta  
 $P(A, B) = \{P(m_1, v_1), P(m_1, v_2), P(m_2, v_1), P(m_2, v_2), P(m_3, v_1), P(m_3, v_2)\}$
- Marginalización

$$P(a) = \sum_i P(a, b_i)$$

## Breve introducción a la probabilidad

### Probabilidad condicionada (I)


- El contexto K:  $P(A) = P(A|K)$
- $P(A|B) = P(A|B,K)$
- Sucesos independientes  
 $P(A|B) = P(A)$
- Sucesos Condicionalmente Independientes  
 $P(A|B,C) = P(A|C)$  A y B son C.I. dado C
- Sucesos dependientes

$$P(A|B) = \frac{P(A,B)}{P(B)}$$

## Breve introducción a la probabilidad

### Probabilidad condicionada (II)

- **Pepe y Juan lanzan la misma moneda, primero lanza pepe**  
a : 'Pepe obtiene cara'  
b : 'Juan obtiene cara'  
 $P(A|B) = P(A)$
- **Igual que antes pero la moneda tiene cierta tendencia a sacar cara (no sabemos cual)**  
 $P(B|A) > P(A)$
- 'A' y 'B' son dependientes con una variable C: 'la moneda tiene tendencia a sacar cara'. Aunque 'A' y 'B' no son independientes si lo son respecto a 'C'  
 $P(A|C) = P(A|B,C)$
- ¿Faltan dependencias en el grafo anterior?



## Breve introducción a la probabilidad

### Regla de Bayes

- Sabemos que:  
 $P(A|B) P(B) = P(A, B)$   
 $P(B|A) P(A) = P(B, A) = P(A, B)$
- Regla de Bayes

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)} = \alpha \cdot P(B|A)P(A)$$

- Constante de normalización  $P(B)$

$$P(B) = \sum_i P(B|A_i)P(A_i)$$

- Regla de la cadena

$$P(A, B) = P(A)P(B|A)$$

$$P(A, B, C) = P(A)P(B|A)P(C|B, A)$$

## Redes Bayesianas


### Definición

- Una red bayesiana es:
  - Un grafo acíclico dirigido para representar dependencias entre variables y mostrar una descripción escueta de cualquier distribución de probabilidad conjunta completa
- Esta formada por
  - Un conjunto de variables aleatorias que forman los nodos de la red. Cada nodo X tendrá adjunta una distribución  $P(X|\text{Padres}(X))$
  - Un conjunto de enlaces que determinan la influencia (dependencia) entre nodos. Si X se conecta con Y se dice que X influencia a Y
- Su finalidad principal es calcular la distribución conjunta de las variables nodo

## Redes Bayesianas

### Semántica (I)


- Dada la siguiente red bayesiana, ¿qué distribución representa?



## Redes Bayesianas

### Semántica (II)

- $P(T, R, A, J, M) =$



$$P(T) \cdot P(R) \cdot P(A|T, R) \cdot P(J|A) \cdot P(M|A)$$

- ¿  $|P(T, R, A, J, M)|$  sin independencia condicional?
  - $2^5 = 32$
- ¿Y con independencia condicional?
  - $2 + 2 + 2^3 + 2^2 + 2^2 = 20$

## Redes Bayesianas

### Inferencia

- ¿Para que queremos la distribución conjunta?
  - A partir de la distribución conjunta podemos contestar cualquier pregunta relativa a la red...
- Varios tipos de inferencia en redes Bayesianas
  - Exacta (caso general)
  - Casos especiales (Kim&Pearl...)
  - Aproximada

## Redes Bayesianas

### Inferencia Exacta (I)

- Inferencia exacta general (funciona para todas la **RR.BB.**)
  - Regla de inferencia general  
(Donde B son las variables buscadas, C las conocidas y D las desconocidas)


$$P(B | C) = \alpha \cdot \sum_D P(B, D, C)$$

- Problema: Mucha complejidad

## Redes Bayesianas Inferencia Exacta (II)

- Ejemplo 1)
  - ¿Cuál es la probabilidad de que suene la alarma si llama María?

$$P(B | C) = \alpha \cdot \sum_D P(B, D, C)$$



- $P(R, T, A, J, M) =$   
 $= P(R) \cdot P(T) \cdot P(A | R, T) \cdot P(J | A) \cdot P(M | A)$

## Redes Bayesianas Inferencia Exacta (III)

- De esta manera obtenemos que

$$\begin{aligned}
 P(A | M) &= \alpha \cdot \sum_R \sum_T \sum_J P(R, T, A, J, M) = \\
 &= \alpha \cdot \sum_R \sum_T \sum_J P(R) \cdot P(T) \cdot P(A | R, T) \cdot P(J | A) \cdot P(M | A) = \\
 &= \alpha \cdot P(M | A) \cdot \sum_R \left( P(R) \sum_T \left( P(T) \cdot P(A | R, T) \cdot \underbrace{\sum_J P(J | A)}_1 \right) \right)
 \end{aligned}$$



## Redes Bayesianas

### Inferencia Exacta (IV)


- Ejemplo 2) ¿ $P(R|J+,M+)$ ? Si sabemos que:

$$P(T) = 0,001$$

$$P(R) = 0,002$$

$$P(A|T,R)=$$

T	R	A
0	0	0,001
0	1	0,94
1	0	0,29
1	1	0,95



$$P(J|A) =$$

A	J
0	0,05
1	0,9

$$P(M|A)=$$

A	M
0	0,01
1	0,7

## Redes Bayesianas

### Inferencia Exacta (V)

- Entonces:

$$P(R | J, M) = \alpha \sum_T \sum_A P(R, T, A, J, M) =$$

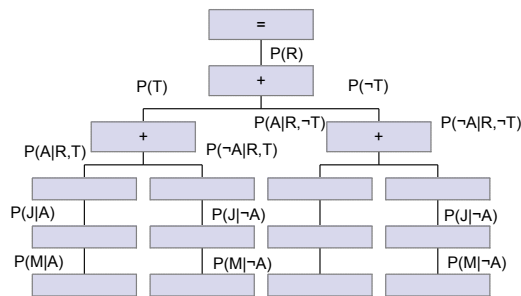
$$\alpha \sum_T \sum_A P(R) \cdot P(T) \cdot P(A | R, T) \cdot P(J | A) \cdot P(M | A) =$$

$$\alpha \cdot P(R) \cdot \sum_T \left( P(T) \cdot \sum_A (P(A | R, T) \cdot P(J | A) \cdot P(M | A)) \right)$$

## Redes Bayesianas Inferencia Exacta (VI)

- Para calcular descomponemos utilizando un árbol

$$\alpha \cdot P(R) \cdot \sum_T P(T) \cdot \sum_A P(A | R, T) \cdot P(J | A) \cdot P(M | A)$$



## Redes Bayesianas Inferencia Exacta (VII)

**P(R|J,M)**

**P(¬R|J,M)**

1 P(A R,T)*P(J A)*P(M A)	0,5985
P(¬A R,T)*P(J,¬A)*P(M ¬A)	0,000025
P(T)* SUM 1	0,00059853
2 P(A R,¬T)*P(J A)*P(M A)	0,5922
P(¬A R,¬T)*P(J,¬A)*P(M ¬A)	0,00003
P(¬T) * SUM 2	0,59163777
<b>TOTAL R+</b>	<b>0,00118447</b>

1 P(A ¬R,T)*P(J A)*P(M A)	0,1827
P(¬A ¬R,T)*P(J,¬A)*P(M ¬A)	0,000355
P(T)* SUM 1	0,00018306
2 P(A ¬R,¬T)*P(J A)*P(M A)	0,00063
P(¬A ¬R,¬T)*P(J,¬A)*P(M ¬A)	0,0004995
P(¬T) * SUM 2	0,00112856
<b>TOTAL ¬R</b>	<b>0,00130899</b>

Cómo  $\alpha \cdot P(R, \neg R) = 1$

<b>P(R J,M)= R</b>	<b>0,47503178</b>
<b>¬R</b>	<b>0,52496822</b>

## Redes Bayesianas

### Inferencia Exacta (VIII)

- Ejemplo 3) ¿ $P(J|R)$ ?

$$\begin{aligned}
 P(J | R) &= \sum_T \sum_A \sum_M P(R) \cdot P(T) \cdot P(A | R, T) \cdot P(J | A) \cdot P(M | A) = \\
 &= P(R) \cdot \sum_T (P(T) \cdot \sum_A (P(A | R, T) \cdot P(J | A) \cdot \sum_M P(M | A)))
 \end{aligned}$$

## Redes Bayesianas

### Inferencia exacta en poliárboles

- Existen algoritmos más eficientes para tipos específicos de redes
  - Modelo de Kim y Pearl
    - Método de inferencia para redes bayesianas.
    - Solo aplicable a un poliárbol.
      - No existe más de un camino entre cada pareja de nodos
    - Se basa en el paso de dos tipos de mensajes entre nodos
      - Para actualizar la credibilidad
      - Para introducir nueva evidencia

## Redes Bayesianas

### Inferencia aproximada (I)

- Sobre la inferencia exacta
  - Redes con conexión multiple son intratables utilizando inferencia exacta
- Inferencia utilizando algoritmos de muestreo aleatorio (Monte Carlo)
  - Existen varios algoritmos
    - Muestreo directo
    - Muestreo por rechazo
    - MCCM (monte Carlo para cadenas de Markov)...
  - Veremos el de muestreo directo

## Redes Bayesianas


### Inferencia aproximada (II)

- Muestreo directo
  - ALGORITMO Muestreo Directo
    - Desde  $k=1$  hasta suficientesMuestras
      - $s[k][ ] = \langle \text{vector de sucesos con } n \text{ elementos} \rangle$
      - Desde  $i=1$  hasta  $n$  hacer
        - $S[k]_i = \text{Obtener una muestra aleatoria de } P(X_i | \text{Padres}(X_i))$
      - fDesde
    - fDesde
    - Devolver  $x$
  - Para responder cualquier pregunta de la red
    - Contar apariciones en  $s[ ]$  de las evidencias
    - Dividir por suficientesMuestras

## Redes Bayesianas Inferencia aproximada (III)

### • Ejemplo) Muestrear la red

$P(T) = 0,001; P(R) = 0,002$



	T	R	A
$P(A T,R)=$	0	0	0,001
	0	1	0,29
	1	0	0,94
	1	1	0,95

	A	J
$P(J A) =$	0	0,05
	1	0,9

	A	J
$P(M A)=$	0	0,01
	1	0,7

1. Muestreo a partir de  $P(\text{Terremoto}) = \langle 0,001 \ 0,999 \rangle$ .  
**supongamos (s.)** que devuelve *falso*
2. Muestreo( $P(\text{Robo})$ ) s. devuelve *falso*
3. Muestreo( $P(\text{Alarma} | \text{Robo=falso}, \text{Terremoto=falso})$ )  
s. devuelve *cierto*
4. Muestreo( $P(\text{Juan} | \text{A=cierto})$ )  
s. Devuelve *cierto*
5. Muestreo( $P(\text{Maria} | \text{A=cierto})$ )  
s. Devuelve *falso*
6.  $X[k] = \langle \text{falso}, \text{falso}, \text{cierto}, \text{cierto}, \text{falso} \rangle$

## Redes Bayesianas Inferencia aproximada (IV)

### • Ejemplo) ¿ $P(R|J,M)$ ?


$P(T) = 0,001; P(R) = 0,002$

	T	R	A
$P(A T,R)=$	0	0	0,001
	0	1	0,29
	1	0	0,94
	1	1	0,95

	A	J
$P(J A) =$	0	0,05
	1	0,9

	A	J
$P(M A)=$	0	0,01
	1	0,7

1. Para obtener  $P(R|J,M)$
2.  $C = \text{Contar } X[k] \text{ que cumpla este patrón}$   
 $X = \langle ?, \text{cierto}, ?, \text{cierto}, \text{cierto} \rangle$
3. Devolver  $C/\text{numeroDeMuestras}$



## Bibliografía

### Base

- Inteligencia Artificial, Un enfoque moderno. Stuart Russell y Peter Norvig, ed Pearson [pág 561]

### Repaso probabilidad e introducción a las RR.BB.

- Probability Theory and Bayesian Belief Bayesian Networks. Norman Fenton. <http://www.dcs.qmul.ac.uk/~norman/BBNs/BBNs.htm>